

问答模块中期记忆持久化方案

1. 背景

在大语言模型交互过程中，会依次产生一系列消息，它们的角色类型是 `system`，`user`，`assistant`。大模型 API 只会接受一系列带有这种角色标签的消息。和大模型交互的时候，我们会发这样类型的一条东西过去：

代码块

```
1  [
2    {
3      "role": "system",
4      "content": "你是一个乐于助人的AI助手，擅长回答关于科学和技术的问题。"
5    },
6    {
7      "role": "user",
8      "content": "请解释一下什么是量子计算？"
9    },
10   {
11     "role": "assistant",
12     "content": "量子计算是一种利用量子力学原理（如叠加和纠缠）进行计算的新型计算范式。与经典计算机使用比特（0或1）不同，量子计算机使用量子比特（qubits），它们可以同时表示0和1，从而实现指数级的计算能力提升，尤其在解决某些复杂问题（如药物发现、材料科学、密码学等）方面具有巨大潜力。"
13   },
14   {
15     "role": "user",
16     "content": "那它和经典计算机有什么本质区别呢？"
17   }
18 ]
```

通过这种方式，大模型就知道了对话的历史，从而可以利用补全机制生成下一条 `assistant` 消息返回给我们。我们会在应用后端的数据库中存储这样的东西：

message_id	conversation_id	role	content
1	1	user	请解释一下什么是量子计算？
2	1	assistant	量子计算是一种利用量子力学原理（如叠加和

		纠缠) 进行计算的新型 计算范式。……
--	--	------------------------

在我们的应用中，如果有一些东西，比如参考文献的内容、来自外部系统的知识等等，希望模型在回答的时候知道，通常也是通过消息传递给大模型。我们会在 user message 里通过 prompt 工程加入。举个例子：如果 user 的消息本来是 “**纤锌矿结构的 BN 的一个 1/3 晶胞中有多少硼原子？**”，我们从一个相关文献里获取了一些知识之后，实际上发给大模型的消息可能是：“**根据论文《xxx》记录，纤锌矿型的 BN 的晶体结构是六方最密堆积。根据上述知识，回答问题：纤锌矿结构的 BN 的一个 1/3 晶胞中有多少硼原子？**”。这就是一个最简单版本的 RAG。

2. 问题描述

在上述设定下，我们会发现用户的聊天记录会越来越长，每次对话都会增加一条 assistant 消息和一条 user 消息。目前大模型的对话能接受的长度是有限的，如果塞进去的内容超出了某个长度，就会出现性能衰减、遗忘等现象。我们想要尽量减少这种现象的发生。

目前业界长上下文对话的一个例子：Claude Code 客户端已经被逆向工程和分析。我们可以参考他们的做法，针对我们的应用情况，对上下文管理、记忆持久化的方案进行探索和优化。


Claude Code 对上下文管理的主要实现方式可以总结为：

- 1. 三层记忆管理
- 2. 92% 阈值触发上下文摘要
- 3. 指定总结需要记忆的重点内容

Claude Code 的两个逆向工程分析仓库放在这里：

https://github.com/shareAI-lab/analysis_claude_code/tree/main

<https://github.com/Yuyz0112/claude-code-reverse/tree/main>





3. 目标

我们需要实现一个 HTTP API，这个 API 的输入是 OpenAI compatible 的 chat completions 接口，输出是对输入消息的总结摘要。最简单的实现是从 [Claude Code Reverse](#) 中提取的提示词开始调试。

4. 评价

需要你用到两周时间先调研一下目前长上下文对话的 benchmark 方法。我认为可能可参考的 benchmark 列在下面，但它们可能已经过时，需要你调研：

- <https://huggingface.co/datasets/tau/scrolls>
- [Needle In A Haystack](#)

如果完全不存在已有的合适 benchmark，可以参考上面的 benchmark 方法设计一套方案，大致按照先提供信息，后在对话中进行其他主题的对话，在一定 token 数之后对很久之前的对话内容进行召回的方法实现。

Baseline：

- 无上下文管理
- 业界先进 LLM 服务